

VISUALIZACIÓN DE DATOS CON D3

Jaime Alba (jaime.alba.cepero@usal.es)

MÁSTER EN INGENIERÍA INFORMÁTICA

Paradigmas Avanzados de Interacción Persona-Ordenador I

29 de mayo de 2021



Índice

0	Objetiv	Objetivo del trabajo				
1	Elecció	Elección del conjunto de datos				
	1.1	Categ	orías de datos	3		
	1.2	Trata	miento previo de datos	4		
2 Método 2.1 2.2		s de visualización evaluados				
		Sankey 5				
		Diagrama de cuerdas				
	2.3	Diagrama de unión jerárquica				
	2.4	Mapa GeoJSON con GeoMercator				
3 Ficheros y s		s y set	up	9		
4	Desarro	llo de	la visualización)		
	4.1	Carga del CSV y creación del mapa y las rutas				
	4.2	Trata	miento de datos1	1		
	4.3	Filtra	do de datos12	2		
	4.3.1	Detalle de la ruta				
	4.3.2	Filtro	por fecha1	3		
	4.3.2	.1	Recarga del gráfico14	4		
	4.3.2	.2	Aplicación del filtro	5		
4.3.3		Filtro	de desplazados	5		
		.1	Recarga del gráfico y aplicación del filtro	5		
	4.3.4	Filtro	de países	5		
	4.3.5	Zoom	10	5		
	4.3.6	Paran	netrización de los path1	7		
5	5 Ejemplos de filtros		iltros1	7		
	5.1 Filtro		por defecto	7		
	5.2	Repre	esentación completa18	3		
	5.3	Movin	nientos de más de 480k personas en 201519	9		



5.4	Desplazados de Siria	19
5.5	España y los refugiados	21

Objetivo del trabajo

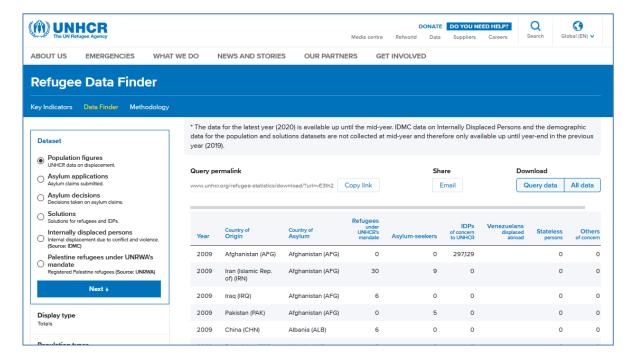
La presente práctica trata sobre la visualización interactiva de datos abiertos.

Se solicita ofrecer una experiencia de usuario a través de la presentación interactiva de información abierta al público, empleando la librería de visualización D3, reflexionando sobre la estructura y tipos de datos elegidos.

1 Elección del conjunto de datos

A partir de la web facilitada con la enumeración de datos abiertos (https://es.wikipedia.org/wiki/Datos_abiertos), y considerando la demo que se hizo en clase de https://ourworldindata.org/, finalmente se eligió la información que ofrece ACNUR sobre población refugiada.

En https://www.unhcr.org/refugee-statistics/download/?url=vE3lh2 se ofrecen datos en formato CSV con los desplazamientos forzosos a partir del año 2009 hasta 2020. Se ha elegido este set de datos por su relevancia social y la perspectiva que ofrece sobre los flujos de desplazados.



1.1 Categorías de datos

La información ofrecida por ACNUR contiene el siguiente detalle:



- Año (*).
- País de origen (*).
- País de asilo (*).
- Refugiados bajo la supervisión de la ONU (*).
- Solicitudes de asilo.
- Desplazados dentro del mismo país (IDP).
- Desplazados del régimen venezolano.
- Personas sin estado.
- Otros.

La visualización propuesta se centrará en los campos marcados con (*), lo que dará una primera perspectiva del problema de los refugiados.

Otro de los puntos considerados ha sido la distancia geográfica recorrida por algunos de ellos ya que, aunque muchos de los desplazamientos han sido por tierra a países vecinos, existen casos en los que el desplazamiento se ha hecho a otro continente de ultramar. La visualización por tanto mostrará el factor "distancia" en la representación de estos datos.

1.2 Tratamiento previo de datos

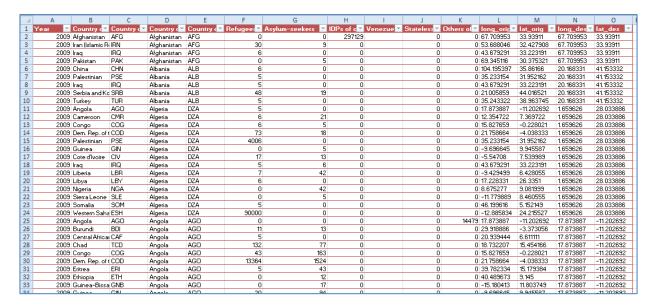
El objetivo es la representación de los desplazamientos de refugiados en un mapa, por lo que será necesario realizar una traducción de los códigos de países a coordenadas geográficas; la web de ACNUR ofrece los nombres (tanto completos como en código de 3 caracteres), pero no su correspondiente latitud y longitud.

Google ofrece bajo licencia Creative Commons una relación de las coordenadas geográficas de países en https://developers.google.com/public-data/docs/canonical/countries_csv; se recuperan de aquí las representaciones de los países (con su código en 2 caracteres).

Para relacionar los países en 3 caracteres ofrecidos por ACNUR con su equivalente ubicación geográfica se utiliza por último la conversión existente en https://github.com/lukes/ISO-3166-Countries-with-Regional-Codes/blob/master/all/all.csv (empleada bajo licencia Creative Commons Attribution-ShareAlike 4.0 International License).

Con la combinación de estos tres orígenes de datos se ha compuesto un fichero CSV con el total de datos ofrecidos por ACNUR y las coordenadas geográficas de origen y destino; se ofrece una captura parcial de esta información en formato tabular (aunque la visualización final trabaja con CSV):





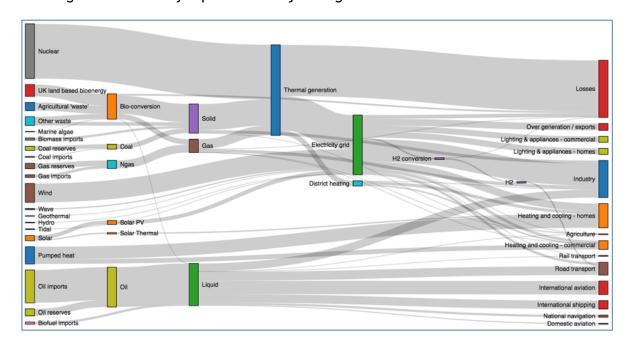
El fichero contiene un total de 57.261 entradas con 15 atributos por cada entrada (como se ha mencionado antes, no se utilizarán todos los atributos).

2 Métodos de visualización evaluados

Existen dentro del ecosistema D3 diversos métodos muy empleados recientemente por su claridad e impacto visuales. Se exponen aquí algunos de los modelos evaluados y las conclusiones de dicha evaluación.

2.1 Sankey

Los diagramas de Sankey representan flujos dirigidos en redes no cíclicas.





El ejemplo anterior es una proyección de la energía consumida por UK en 2050, estando a la izquierda el origen y a la derecha el destino.

Esta visualización se ha descartado al no considerar la distancia geográfica, además de requerir mucho espacio al tener que representar más de 200 países en ambos ejes. La información quedaría presumiblemente muy poco clara.

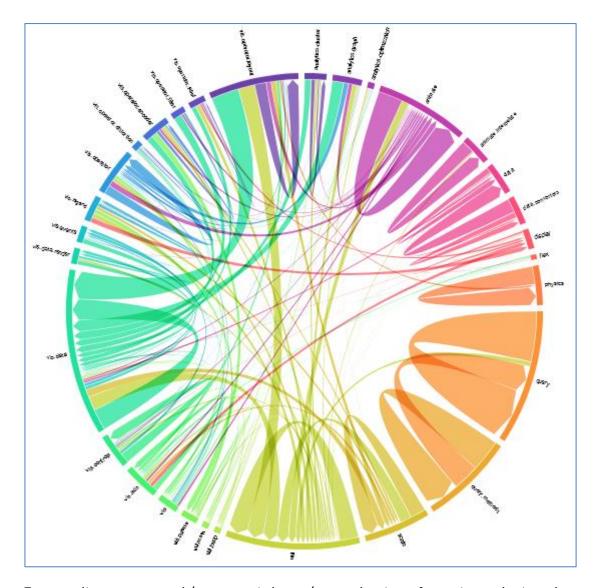
También se ha considerado que no ofrece una perspectiva real sobre la distancia geográfica de los desplazados.

De la misma manera, se desaprovecharía una de las características de estos diagramas como son los estadios intermedios. Los datos no invitan a una compartimentalización de este tipo, salvo por la posibilidad de separar por continente al que pertenece cada país (información que además habría que añadir manualmente al CSV).

2.2 Diagrama de cuerdas

Este tipo realiza una relación de datos estando éstos distribuidos en un círculo, uniendo los distintos elementos del set con cuerdas de grosor proporcional al peso de la relación:





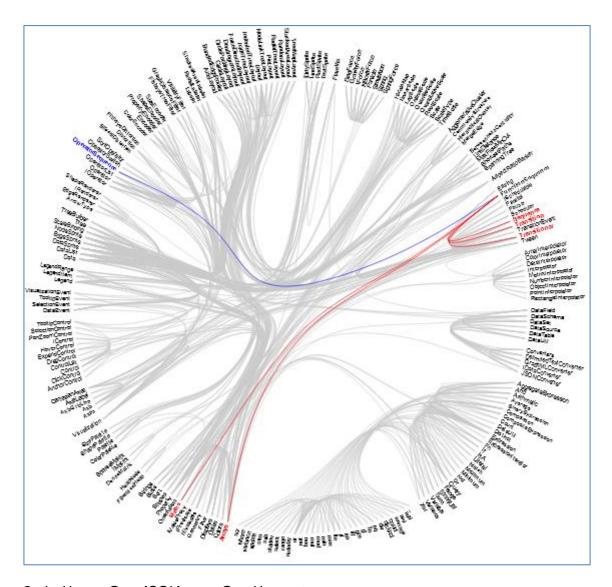
En este diagrama se podrían repartir los países en la circunferencia y relacionarlos según los flujos de desplazados.

Los principales problemas son de nuevo el gran volumen de datos a exponer y el nulo peso que se le da a la distancia entre países. Una posible distribución por continentes podría realizarse pero, como se ha indicado en el punto anterior, habría que añadirla manualmente al set.

2.3 Diagrama de unión jerárquica

Otra de las opciones descartadas ha sido este modelo de diagrama; la razón es que requiere de una representación jerárquica de los datos para poder ser utilizado (además de resultar sorprendentemente complejo en su uso):





2.4 Mapa GeoJSON con GeoMercator

Finalmente se ha optado por una representación en forma de mapa con proyección tipo Mercator con los datos facilitados por GeoJSON.





Esta representación vectorial permite un volcado de las coordenadas geográficas, y el trazado de arcos entre los países de origen y destino de los desplazamientos. Igualmente se ofrece la opción de zoom sobre el mapa, así como la posibilidad de recorte, desplazamiento, etc.

Pese a que no es geográficamente realista (existe una distorsión volumétrica asociada), es una de las visualizaciones más reconocidas del globo terráqueo, y permite realizar una valoración de las distancias recorridas por los refugiados.

3 Ficheros y setup

La entrega se compone de los siguientes ficheros:

- Fichero principal: index.html
 - En este fichero se distribuyen en la página los elementos que componen el marco de información y filtrado, y crea el recipiente principal para el mapa.
- Fichero de script D3: carga_csv.js
 - Script con los elementos D3 de carga de datos (considerando los posibles filtros) y representación de las rutas, así como el texto de información.
- Hoja CSS: estilos.css
 - Fichero con los diferentes estilos, y que contiene las referencias de posiciones de cada elemento de la página.
- Ficheros de datos: migraciones.csv y lista_paises.csv



- Archivos con los datos a cargar en formato CSV, incluyendo las adaptaciones indicadas en secciones anteriores (migraciones.csv) y un listado alfabético de los países (lista_paises.csv).
- Ficheros de imágenes: logoUSAL_grande.png y logoACNUR.jpg

Todos los ficheros se ubicarán en el mismo directorio, pero debido a las restricciones CORS no se puede hacer un acceso sin emplear un servidor de aplicaciones. En el desarrollo se ha empleado un Tomcat bajo Windows.

La instalación requiere además de acceso a internet desde el web Server para la descarga de los datos de GeoJSON y los ficheros D3.

4 Desarrollo de la visualización

En esta sección se recogen los principales desafíos de diseño encontrados y las soluciones adoptadas.

4.1 Carga del CSV y creación del mapa y las rutas

Uno de los puntos más complejos de asimilar de D3 es el proceso de carga de los elementos. El enfoque inicial había sido secuencial (primero leer CSV, luego generar el SVG con la representación y finalmente escribir los datos), pero se descubrió que de esta manera la carga del CSV finalizaba después de la creación del gráfico vectorial SVG, por lo que no se reconocían los datos.

Para evitarlo, el grueso de la operación con elementos D3 se da dentro de la función asociada a la carga del CSV (en el fichero carga_csv.js):

Dentro de esa función se realizan el procesamiento de los datos recogidos del fichero (país de origen, destino, total de desplazados y año), la creación de la imagen SVG y el volcado en ésta de la proyección del mapa.

Por tanto, y aún dentro de la función asociada a la carga del CSV, es necesario llamar al siguiente método:

La carga del mapa (sin rutas) tiene inicialmente este aspecto:





En esta misma sección de carga del mapa se generan los distintos "path" o rutas entre países a partir de la información procesada desde el CSV. Se considera la información geográfica de cada entrada para trazar una línea curva entre el punto de origen y el punto de destino.

Igualmente, se define la "punta de flecha" de las rutas, que indica el sentido del desplazamiento de refugiados, como una clase de objetos de tipo "marker".

4.2 Tratamiento de datos

Una vez recogidos los datos del fichero CSV de refugiados, se recorre todo el fichero filtrando por países de origen y destino, fechas de inicio y fin y movimiento de personas (por año). Estos filtros se pasan en la URI del script cuando éste es invocado desde "index.html".



Esta información se va acumulando en unas variables que se utilizan después para componer las rutas una única vez (recorrer el CSV en bruto generaría tantas posibles rutas iguales como años de filtro, por ejemplo filtrando con 5 años podrían crear 5 veces la ruta entre el país A y el B).

Esta composición de rutas incluye las coordenadas geográficas de origen y acogida, y se vuelcan como elementos "path" dentro del SVG considerando el volumen de personas que representan (a más personas en la ruta, mayor grosor, como se explica más adelante).

4.3 Filtrado de datos

La primera versión de la visualización (carga de GeoJSON y generación de d3.geoMercator), incluyendo todos los datos disponibles en el CSV para 2009, producía el siguiente resultado:



A partir de esta visualización inicial se fueron aplicando las siguientes mejoras.

4.3.1 Detalle de la ruta

Al pasar el ratón por encima de cada uno de los paths se mostrará un recuadro de información con el origen, el país de acogida y el total de personas implicadas en el movimiento.

La siguiente imagen muestra una versión inicial de esta información flotante:





La información flotante se consigue añadiendo a cada path (definido dentro del método "d3.geojson" del fichero "carga_csv.js") sendas funciones "onmouseover" y "onmouseout", que trabajan con una capa flotante, quitándole o poniéndole opacidad y moviéndola a la posición del evento de ratón; cada path añade en esta capa el texto con la información sobre ese flujo concreto de refugiados.

4.3.2 Filtro por fecha

El objetivo de este filtro es permitir definir un rango de fechas (entre 2009 y 2020) en el cual limitar la visualización de datos.

El primer elemento relevante es una barra creada mediante "d3-simple-slider" (en concreto un sliderBottom), y generada en el fichero "index.html" dentro del método JavaScript "barraTiempo()". En este slider se definen entre el rango a mostrar, el número de marcas (o ticks) en la barra y la distancia entre cada elemento del rango (1 en este caso, ya que tenemos información de año en año).



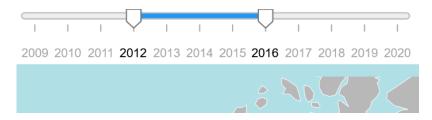
```
recarga_script();
})

;

// Se ubica en pantalla mediante un 'g'.
var gRange = d3
    .select('div#slider-range')
    .append('svg')
    .attr('width', 450)
    .attr('height', 100)
    .append('g')
    .attr('transform', 'translate(15,10)');

// Se arranca el slider.
gRange.call(sliderRange);
```

Esta barra se vuelca dentro de un elemento SVG que se muestra por pantalla en la esquina superior izquierda:



La creación de esta barra de tiempo, así como de la barra de rango de desplazados y los selects para filtrado por países (ver secciones siguientes), se invocan en el "onLoad" de la página.

4.3.2.1 Recarga del gráfico

Uno de los elementos interactivos en los que más se ha trabajado ha sido en la recarga dinámica del gráfico del mapamundi con las rutas. Esta recarga se realiza cuando se cambia el rango de fechas, así como cuando se actualiza cualquiera de los filtros que se expondrán a continuación en el documento.

La solución adoptada incluye un manejo de los elementos de DOM que ofrece SVG; cuando se invoque el evento "end" al soltar cualquiera de los límites de la barra, se realizarán dos acciones:

- Borrado de la imagen SVG que contenía el resultado la carga y procesamiento del CSV (método "borra_mapa()" que selecciona el elemento "imagen" y lo borra), y se regenerará una nuevo elemento SVG "imagen" donde se volcará el nuevo mapa.
- Nueva llamada al script "carga_csv.js" desde el método "recarga_script()", indicándole los nuevos filtros con los que recargará el fichero CSV y actualizará los parámetros de visualización.

Los filtros que se pasarán al script en su recarga son: año de inicio y fin, máximo y mínimo de desplazamientos de personas, país de origen y país de acogida. El año de inicio y fin se recoge del slider generado en la función "barraTiempo()". Los otros parámetros se obtienen a partir de los elementos que se describen a continuación.



4.3.2.2 Aplicación del filtro

Una vez actualizado el rango se solicitará la recarga del fichero CSV considerando las fechas de inicio y fin de dicho rango. Este procesamiento se realiza en "carga_csv.js", que recogerá del DOM el elemento "script" al que se le han añadido los parámetros en forma de URI component (carga_csv.js?anno_ini=<valor1>&anno_fin=<valor2> ...).

El criterio seguido es que se acumularán todos los movimientos de personas entre esos años, y se mostrará el sumatorio para cada una de las rutas.

4.3.3 Filtro de desplazados

Al igual que con las fechas, se compone un filtro de tipo "sliderBottom" (perteneciente a "d3-simple-slider") en fichero "index.html". En este caso el rango estará entre 0 y 4 millones.



El valor 0 aparece en el CSV cuando hay otros atributos localizados dentro del registro, como por ejemplo desplazamientos dentro del mismo país o solicitudes de asilo; el máximo de 4 millones es un redondeo al alza sobre el máximo valor para un año único (3.622.366 desplazados hacia Turquía por el conflicto en Siria en 2018).

4.3.3.1 Recarga del gráfico y aplicación del filtro

El proceso ante cualquier evento de cambio en el valor de este filtro ("end") es el mismo que el expuesto en el filtro para los años: se elimina el gráfico SVG y se recarga de nuevo el script que lo genera, ya con los nuevos parámetros (carga_csv.js? ... min=<valor minimo>&max=<valor maximo> ...).

En este caso la aplicación del filtro es algo más compleja, ya que éste no se refiere al total de desplazados en el rango (por ejemplo, entre 2010 y 2015), sino al total de desplazados cada año. Se ha optado por este enfoque para evitar crear un filtro demasiado extenso (en el peor de los casos, podría ir de 0 a 182 millones).

Por tanto, la lectura de estos dos primeros filtros podría interpretar por ejemplo como "muestra los movimientos de entre 0 y 10.000 personas que han tenido lugar entre 2018 y 2020".

4.3.4 Filtro de países

Adicionalmente se han añadido dos filtros mediante sendos select, uno para el país de origen y otro para el país de destino de los refugiados:



Estos select se componen mediante D3 en "index.html", en el método "rellena_select()". Los datos de los países se cargan desde la misma llamada a d3.csv:



```
// Función que rellena el select de país de origen
function rellena select()
  // Añadimos textos a los div (ya definidos en el HTML)
  var txtFiltro = d3.select('body').select('div#seleccion-pais').html("Pais origen:");
  var txtFiltroDestino=d3.select('body').select('div#seleccion-pais-d').html("País destino:");
  // Accedemos al fichero
  d3.csv("./lista paises.csv", function(data)
     var select =
          d3.select('body')
          .select('div#seleccion-pais')
          .append('select').attr('class','seleccion');
     var selectdestino =
           d3.select('body')
          .select('div#seleccion-pais-d')
          .append('select').attr('class','seleccion');
     // Se cargan los datos en nuestro array "links".
     for (i=0; i < data.length ; i++)
        select.append("option")
           .attr("value", data[i].NombrePais)
           .text(data[i].NombrePais);
        selectdestino.append("option")
           .attr("value", data[i].NombrePais)
           .text(data[i].NombrePais);
     select.on("change", function(d) {
        pais filtro = d3.select(this).property("value");
        borra mapa();
        recarga_script();
     selectdestino.on("change", function(d) {
        pais filtro destino = d3.select(this).property("value");
        borra mapa();
        recarga script();
     });
  });
```

En ambos select se cargará la misma información, y ambos realizan ante un evento "change" las mismas llamadas para eliminar la imagen y recargar el script que la compone (carga_csv.js? ... pais=<pais_origen>&paisdestino=<pais_destino> ...).

4.3.5 Zoom

Mientras que los cuatro filtros anteriores se componían en el "index.html", el zoom (para acercar el mapa con calidad vectorial cuando se hace doble clic o se usa la rueda del ratón) se define en el "carga_csv.js", durante la configuración de la imagen SVG (y antes de volcar el mapa en ella):

```
svg = d3.select("svg#imagen")
```



```
.attr("width", ancho)
.attr("height", alto)
.style("border", "none")
.style("background-color", "none")
.call(d3.zoom()
    .on("zoom", function () {
        svg.attr("transform", d3.event.transform)
    })
    .scaleExtent([1 ,4]) // Limitamos el zoom a 4x
    .translateExtent([[0, 0], [ancho, alto*1.1]]) // Limitamos el desplazamiento.
)
.append("g")
;
```

Se definen dos parámetros de zoom y desplazamiento de imagen:

- scaleExtent, que permite limitar el zoom entre dos valores, aquí entre 1 y 4.
- translateExtent, que permite mover la imagen una vez hecho zoom.

Con esta configuración, el acercamiento progresivo se hará con la rueda del ratón o con doble click sobre la imagen, mientras que el alejamiento se realizará con la rueda del ratón.

4.3.6 Parametrización de los path

Otro de los elementos añadidos para facilitar el visionado de las rutas es la modificación del grosor y el color de las rutas de refugiados en función del número que implica cada ruta.

Se han aplicado los siguientes criterios:

- Hasta 1.000 personas: color negro, grosor 0.5.
- Entre 1.000 y 10.000 personas: color negro y grosor 1.
- Entre 10.000 y 100.000 personas: color negro y grosor 1.5.
- Entre 100.000 personas y 1.000.000: color negro y grosor 2.
- Más de 1.000.000 de personas: color rojo y grosor 3.5.

Estos atributos se configuran durante la elaboración de las rutas mediante elementos "path" al SVG del mapa. Una vez recopilados los datos de acuerdo a los filtros, se recorren los enlaces finales y para cada uno de ellos se compone esta línea empleando las coordenadas geográficas explicadas anteriormente en el documento, y considerando el total de desplazados que hay en cada una de las rutas.

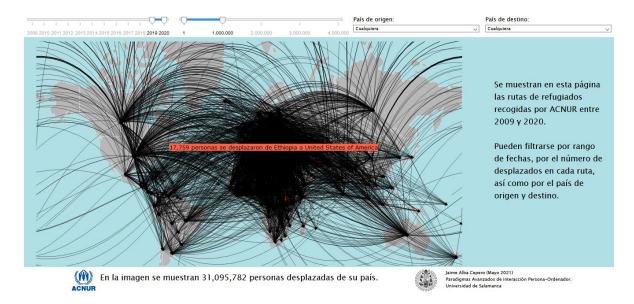
5 Ejemplos de filtros

Se recoge en esta sección el resultado de aplicar algunos de los filtros explicados más arriba, y que consiguen ofrecer una experiencia interactiva al usuario.

5.1 Filtro por defecto

El valor por defecto del filtro es un rango entre 2019 y 2020, con rutas de hasta 1 millón de desplazados:



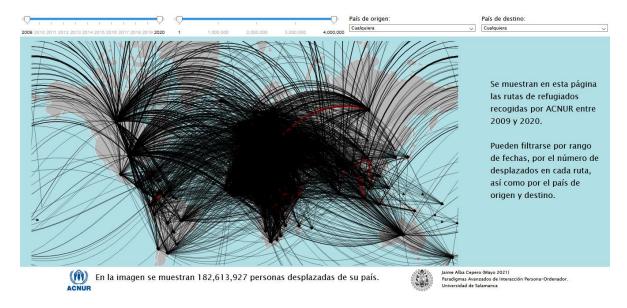


El objetivo de crear una "splash-screen" con tanta información es en cierto modo sorprender al usuario dándole un primer vistazo del impacto de los movimientos de refugiados.

Se ha incluido también una captura del aspecto final del "onMouseOver" aplicado a la ruta entre Etiopía y los Estados Unidos. Se puede ver que los desplazamientos de hasta 1 millón de personas entre 2019 y 2020 supusieron 17.759 desplazamientos de refugiados.

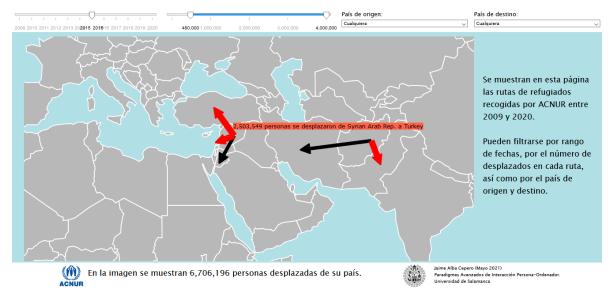
5.2 Representación completa

El segundo ejemplo es la ampliación de los filtros para mostrar toda la información disponible. Aunque las rutas son muy similares a las de la representación anterior, sí que se puede ver en la parte inferior el total de personas representadas en la visualización:





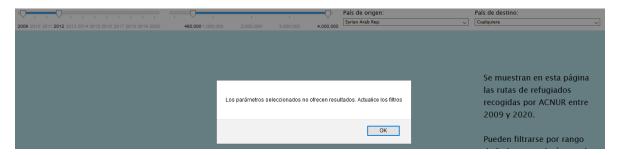
5.3 Movimientos de más de 480k personas en 2015



Este filtro muestra para un único año los desplazamientos de entre 480 mil y 4 millones de personas. Se puede ver el detalle, tras aplicar un zoom al mapa, el origen y destino de estos movimientos de refugiados (6.706.196 personas), con origen Siria y Afganistán.

5.4 Desplazados de Siria

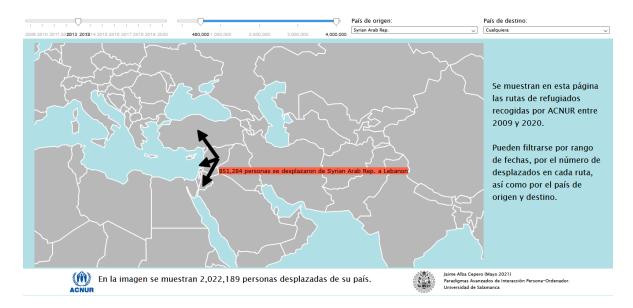
Para calcular este dato se han aplicado varios filtros. El primero consiste en ver cuántas personas tuvieron que huir de Siria entre 2009 y 2012:



El mensaje popup mostrado aparece cuando los filtros no incluyen ningún dato.

A partir de 2013 la situación es muy distinta; para ese año se muestran a continuación los desplazamientos de más de 480.000 personas (rutas de huida más empleadas):





Sólo en 2013 huyeron 2.022.189 personas de Siria (sin contar desplazamientos de menos de 480k personas), 851.384 de las cuales fueron a Líbano.

Ampliar el rango de fechas desde 2013 hasta 2020 da una idea del drama vivido en Siria, con un total de 36.758.142 desplazados a otros países empleando estas rutas mayoritarias, de los cuales más de 21 millones fueron a Turquía. Sorprende también ver que la ruta a Alemania supera el millón de desplazados (2.163.725 personas) en esa franja de tiempo.



Sin embargo estos diagramas mostraban las rutas mayoritarias. La imagen completa (abriendo el filtro de personas y de fechas) ofrece una visión aún más impactante:





5.5 España y los refugiados

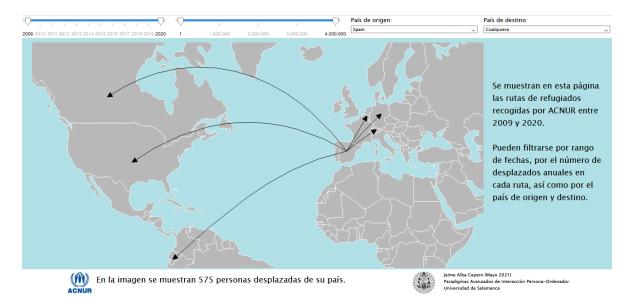
Se incluye por último una serie de filtros con España como destino (y origen) de refugiados. En primer lugar, la búsqueda en toda la serie histórica de España como receptor arroja esta representación:



Desde 2009, España ha acogido 223.306 refugiados. Como dato comparativo, se comprueba que Francia ha acogido a 3.420.513 personas en ese mismo período, y Alemania a 8.031.735 (sólo en 2020, Alemania acogió a 5 veces más refugiados -1.111.350- que España en 11 años).

Sorprende ver que desde España también se han producido situaciones en las que personas se han acogido al estatus de refugiado al desplazarse a otro país, en total 575 personas desde 2009:





Por último se incluye el número de refugiados que han llegado a España desde Venezuela desde 2016:



Jaime Alba Cepero